

Cadenas ocultas de Markov para predicción de acciones colombianas

José Ricardo R. Hernández
Universidad de los Andes
Bogotá, Colombia
j.ricardo@uniandes.edu.co

ABSTRACT

Este artículo implementa un modelo de Cadenas Ocultas de Markov (HMM) para la predicción de precios de cierre en el mercado accionario colombiano, utilizando datos de alta frecuencia obtenidos de Yahoo Finance para Banco de Bogotá y Terpel. La metodología se centra en la detección de regímenes de volatilidad latentes. Para la selección del modelo óptimo, se empleó el Criterio de Información Bayesiano (BIC), determinando una estructura de dos estados como la más parsimoniosa. El desempeño predictivo fue evaluado mediante la Precisión Direccional (DPA) y el Error Porcentual Absoluto Medio (MAPE). Los resultados empíricos muestran una precisión direccional superior al 56% y un MAPE inferior al 1% en pruebas fuera de muestra, superando el umbral de aleatoriedad y validando la capacidad del modelo para identificar patrones no lineales en mercados emergentes.

KEYWORDS

Cadenas ocultas de markov, acciones, acciones colombianas, modelo de difusión

ACM Reference format:

José Ricardo R. Hernández. 2017. Cadenas ocultas de Markov para predicción de acciones colombianas. In *Proceedings of Noviembre 2025, Modelos de Interacciones sociales*, 5 pages.
DOI: 10.1145/nnnnnnn.nnnnnnn

1 INTRODUCCIÓN

Los Modelos Ocultos de Markov (HMM, por sus siglas en inglés) son un instrumento que ha sido útil en diferentes campos del saber cuantitativo. Inicialmente, su auge en aplicación se remonta hacia los años 70, donde un grupo de matemáticos implementaba dicho modelo para la descryptación de documentos soviéticos desde el Instituto de Defensa de EE.UU [10]. Con el pasar de los años, los modelos ocultos de Markov se han instaurado en áreas como computación, medicina, ingeniería y finanzas, entre otras [4].

Las cadenas ocultas de Markov han resultado especialmente útiles en el sector financiero [6], específicamente en el mercado de capitales. El mercado de capitales se caracteriza por transar acciones, títulos de deuda y divisas cuyo valor suele estar reflejado en un precio. Así mismo, en este nicho financiero se aborda una teoría que

sentencia toda transacción como eficiente [3], lo cual implica que no habría lugar para especular con precios. Sin embargo, es posible hoy en día, tal como ha ocurrido históricamente, que instituciones financieras se lucren de precios que no son eficientes.

En paralelo, con el avance tecnológico de las últimas décadas, el trading de alta frecuencia es considerado como el estándar en este sector, negociando aproximadamente 10 billones de USD [8]. Es por esto que en el siguiente artículo se replica la metodología expuesta por Catello et al. (2023), cuyas bases teóricas se fundamentan en Gupta et al. (2012) y en la enseñanza metodológica de Lawrence Rabiner (1989) sobre los algoritmos detrás de los Modelos Ocultos de Markov [5, 7].

2 LITERATURA PREVIA

Tal como se mencionó anteriormente, el trabajo de Catello et al., publicado en 2023, fue el pilar a la hora de replicar este ejercicio con acciones colombianas. De dicho artículo se destaca el uso de una nueva métrica de error: la DPA. La Precisión Predictiva Direccional (Direction Predictive Accuracy - DPA) calibra los estados latentes que, en efecto, tuvieron una predicción correcta relativa al precio de cierre de la acción. En paralelo, utilizan cambios fraccionarios para el precio diario de la acción entre el mayor vendido, el menor y el precio de cierre [2]. La anterior partición cambiaría entre cambios fraccionarios proviene de Gupta y Dhingra (2012), donde adicionalmente discretizaron el vector de fracciones cambiarias diarias; lo cual hace que el modelo funcione mejor a la hora de encontrar la secuencia de observaciones con mayor verosimilitud entre todos los posibles escenarios [5].

3 METODOLOGÍA

El principal marco teórico para implementar cadenas ocultas de Markov proviene de Rabiner (1989) [7]. Con el fin de tener una idea de cómo se compone una cadena de Markov oculta, se describirá brevemente el marco.

Por un lado, toda cadena de Markov parte de una propiedad (llamada propiedad de Markov) que señala que la transición entre estados a lo largo del tiempo solo depende del estado actual. Tal como se observa en la ecuación (1), la dependencia entre estados indexados en el tiempo t , X_t , solo se caracteriza por el estado anterior, mas no de un histórico de estados completos.

$$\mathbb{P}[X_{t+1} | X_t] = \mathbb{P}[X_{t+1} | X_t, X_{t-1}, X_{t-2}, \dots] \quad (1)$$

Por otra parte, los estados S son ocultos, i.e., no los podemos ver directamente. Los estados ocultos se denotan como $S = \{S_1, S_2, \dots, S_N\}$, donde pueden existir hasta N estados. En consecuencia, una cadena de Markov oculta se caracteriza por incluir matrices de emisión en función de observaciones $B = \{\forall i \in S \mid b_i(o_t) \in (0, 1)\}$, donde

Permission to make digital or hard copies of part or all of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for third-party components of this work must be honored. For all other uses, contact the owner/author(s).

Noviembre 2025,

© 2025 Copyright held by the owner/author(s). 978-x-xxxx-xxxx-x/YY/MM...\$15.00
DOI: 10.1145/nnnnnnn.nnnnnnn

cada observación en el tiempo t , o_t , es un símbolo que nos ayuda a inferir si estamos en algún estado oculto de forma probabilística.

$O = \{o_1, o_2, \dots, o_T\}$ es el conjunto de observaciones secuenciales a lo largo del tiempo hasta T . En paralelo, para transicionar entre estados debemos incluir una matriz de transición A tal que $A = \{i, j \in S \mid a_{i,j}\}$, donde la matriz es estocástica [9]. Por otra parte, identificar por medio de una distribución de probabilidad en cuál estado oculto se comenzó inicialmente en la secuencia se escribe como $\pi = (\pi_1, \pi_2, \dots, \pi_N)$.

Por lo tanto, una cadena oculta de Markov (HMM) se define como $HMM = (S, A, B, O, \pi)$ y, escrito en notación probabilística para los parámetros $\lambda = (A, B, \pi)$:

$$HMM = \begin{cases} \mathbb{P}[X_{t+1} = S_j \mid X_t = S_i], & a_{i,j}, \text{ donde para cualquier estado oculto } i, \sum_i^N a_{i,j} = 1 \\ \mathbb{P}[o_t \mid S_i], & b = b_i(o_t) \\ \mathbb{P}[S_1], & \pi_i \end{cases}$$




Figure 1: Evolución del modelo oculto hasta el tiempo T .

Tal cual se observa en la Figura 1, la rejilla de una cadena oculta de Markov se caracteriza por dicha estructura [1]. La secuencia de observaciones evaluada en la probabilidad de emisión es la que nos indica en cuál posible estado oculto estamos ubicados.

Ahora bien, está bastante documentada la forma en que se entrena y se solucionan los problemas asociados a computar los parámetros λ [1, 7, 9]. En este artículo vamos a explicar en qué consiste cada uno de estos problemas superficialmente y cómo se solucionan, sin entrar detalladamente en la matemática formal.

El primer problema, de *evaluación*, consiste en poder computar la probabilidad de que la secuencia de datos observados O siga los parámetros λ . Poder realizar computacionalmente $\mathbb{P}[o \mid \lambda]$ de forma eficiente es el problema a solucionar, puesto que si se encuentra $\mathbb{P}[o \mid \lambda] = \sum_{X_1, X_2, \dots, X_T} \pi_{X_1} b_{X_1}(o_1) a_{X_1 X_2} b_{X_2}(o_2) \dots a_{X_{T-1} X_T} b_{X_T}(o_T)$ sumando cada secuencia de estados, necesitaríamos $2TN^T$ computaciones. Es ineficiente. Rabiner expone que con el algoritmo *Forward* el orden de complejidad se reduce a N^2T ; mucho más rápido.

El segundo problema, *decodificación*, consiste en encontrar la secuencia de estados ocultos $X_1, X_2, \dots, X_T$ que más se acerque de acuerdo a las observaciones y parámetros λ . Lo anterior se soluciona con el algoritmo de Viterbi, cuyo procedimiento consiste en utilizar un método de programación dinámica.

Por último, el *problema de entrenamiento* consiste en modificar los parámetros λ tal que se maximice $\mathbb{P}[o \mid \lambda]$. Si bien estamos definiendo la misma probabilidad planteada en el problema de evaluación, la diferencia consiste en encontrar la máxima verosimilitud

de los parámetros λ tal que se cumplan las restricciones de convexidad de cada uno.

Una vez el modelo tiene características deseables de predicción, se quiere encontrar una cantidad de estados ocultos que mejor verosimilitud tenga de acuerdo a algún criterio. Para el siguiente documento vamos a utilizar el BIC (Bayesian Information Criterion) tal que se pueda estimar una cantidad de estados óptima. Donde $\hat{L}$ es la verosimilitud máxima; es decir, el valor óptimo de $\mathbb{P}[O \mid \hat{\lambda}]$. Si la verosimilitud es mayor, entonces la transformación $-2 \ln(\hat{L})$ toma valores negativos. Por otra parte, k es el número de parámetros que el modelo está estimando.

$$BIC = -2 \ln(\hat{L}) + k \ln(N) \quad (2)$$

Se escoge el modelo cuyo BIC sea el más bajo.

4 DATOS

Se utilizaron 2 acciones colombianas para estimar y entrenar el modelo. La primera es del Banco de Bogotá y la segunda de Terpel. Los datos fueron extraídos por medio de Yahoo Finance con el paquete *QuantMod* en R. Se necesitan para cada acción 4 variables del valor transado diariamente: Valor de apertura (Open), valor de cierre (Close), valor más alto transado en el día (High) y valor más bajo transado en el día (Low).

Por lo tanto, replicando el cambio fraccionario de Gupta et al. (2012) y Catello et al. (2023), el vector O se define:

$$O = \left(\frac{Close - Open}{Open}, \frac{High - Open}{Open}, \frac{Open - Low}{Open} \right) \quad (3)$$

Por otra parte, para medir qué tan erróneo es el modelo y qué tan preciso es, se utilizará por un lado el promedio absoluto del error de predicción (MAPE) y la precisión direccional correcta (DPA) implementada por Catello et al. (2023) [2].

El Mean Absolute Prediction Error (MAPE) para el día i con la predicción p_i y cierre real del precio de la acción c_i es:

$$MAPE = \frac{1}{n_p} \sum_{i=1}^{n_p} \frac{|p_i - c_i|}{|c_i|} \cdot 100\% \quad (4)$$

El DPA se define con una función delta de Kronecker:

$$DPA = \frac{1}{n_p} \sum_{i=1}^{n_p} \delta(\text{sgn}(p_i - s_i), \text{sgn}(c_i - s_i)) \cdot 100\% \quad (5)$$

donde n_p es el número total de predicciones, p_i es el valor predicho del precio de cierre de la acción, c_i es el precio real de cierre y s_i es el precio de apertura de la acción.

La primera diferencia mide la dirección predicha entre el precio de apertura y el precio de cierre. Si la diferencia es positiva, entonces $\text{sgn}(+)$ toma el valor de 1; de lo contrario, toma el valor -1. En paralelo, la segunda diferencia mide si el valor real de cierre subió o bajó respecto a la apertura. Si ambos signos son positivos, entonces la función δ toma el valor de 1, indicando que el modelo tomó la dirección correcta. Si ambos son contrarios (una parte toma el valor de 1 y otra -1, o al contrario), entonces δ toma el valor de 0 y no aporta al promedio del DPA.

Table 1: Desempeño del Modelo HMM fuera de muestra (Out-of-Sample)

Activo Financiero Direccional	N	Precisión	
	MAPE		
Banco de Bogotá (Diario)	228	56.34%	0.88%
Terpel (Diario)	228	57.07%	0.96%

5 RESULTADOS

La Tabla 1 resume la capacidad predictiva del modelo de Cadenas Ocultas de Markov para dos de los activos más líquidos del mercado colombiano: Banco de Bogotá y Terpel. El modelo fue evaluado en un horizonte fuera de muestra (out-of-sample) de 228 días de negociación para garantizar la robustez de los hallazgos.

Se aprecia una consistencia notable en el desempeño del modelo para ambos activos. Para Terpel, el modelo alcanzó una precisión direccional del 57.07%, mientras que para Banco de Bogotá se obtuvo un 56.34%. Estos resultados son superiores al umbral del 50% esperado por el azar (o una caminata aleatoria), lo que sugiere que el modelo HMM logra capturar exitosamente los regímenes de volatilidad latentes que preceden a los movimientos de precios en el mercado local.

Análisis del Error: En términos de ajuste, el Error Porcentual Absoluto Medio (MAPE) se mantuvo por debajo del 1% en ambos casos (0.88% y 0.96% respectivamente). Este bajo nivel de error indica que el modelo no solo acierta en la dirección de la tendencia, sino que también estima con alta precisión los niveles de precios futuros, validando su utilidad potencial para la gestión de riesgos y la toma de decisiones de inversión.

La gráfica de la Figura 2 muestra el valor del BIC para modelos HMM con distintos números de estados ocultos ($K \in [2, 8]$). El punto rojo indica el modelo óptimo (mínimo BIC) para cada activo. Se observa que para ambas acciones, la estructura más parsimoniosa corresponde a $K = 2$.




Figure 2: Criterio de Información Bayesiano (BIC) por número de estados.

6 CONCLUSIONES

El presente estudio evaluó la capacidad predictiva de los Modelos Ocultos de Markov (HMM) en el mercado de valores colombiano,

centrándose en dos de sus activos más líquidos: Banco de Bogotá y Terpel. Los hallazgos empíricos permiten extraer tres conclusiones fundamentales que desafían la noción de una eficiencia de mercado estricta en el contexto local.

En primer lugar, los resultados obtenidos validan la eficacia del modelo HMM para capturar la dinámica de precios en la Bolsa de Valores de Colombia. Con una Precisión Direccional (DPA) superior al 56% y un Error Porcentual Absoluto Medio (MAPE) inferior al 1% para ambos activos, se demuestra que el modelo supera sistemáticamente el rendimiento esperado por una caminata aleatoria. Esto sugiere que existen patrones latentes y dependencias temporales en los precios que pueden ser explotados mediante algoritmos de aprendizaje automático, contradiciendo parcialmente la hipótesis de que los precios siguen un comportamiento puramente estocástico e impredecible.

En segundo lugar, el análisis mediante el Criterio de Información Bayesiano (BIC) reveló que una estructura de dos estados ($K = 2$) es la más parsimoniosa y efectiva para modelar estos activos. Esta dualidad de estados sugiere que el comportamiento de las acciones colombianas oscila principalmente entre dos regímenes de mercado definidos (posiblemente asociados a baja y alta volatilidad, o tendencias alcistas y bajistas), simplificando la complejidad del modelado sin sacrificar precisión predictiva.

Finalmente, este trabajo aporta evidencia a favor del uso de metodologías no lineales como los HMM para la gestión de riesgos y la construcción de estrategias de trading algorítmico en mercados emergentes. Si bien la eficiencia del mercado implica la dificultad de obtener retornos anormales constantes, la capacidad del modelo para anticipar la dirección del precio con una tasa de éxito superior al 50% abre la puerta a estrategias de inversión más sofisticadas que las tradicionales. Futuras investigaciones podrían extender este enfoque incorporando variables exógenas macroeconómicas o aplicando el modelo a un portafolio diversificado para validar su robustez en diferentes ciclos económicos.

REFERENCES

[1] Christopher M. Bishop. 2006. *Pattern Recognition and Machine Learning*. Springer, New York, 612.

[2] L. Catello, L. Ruggiero, L. Schiavone, and M. Valentino. 2023. *Hidden Markov Models for Stock Market Prediction*. Technical Report. Università degli Studi di Napoli Federico II.

[3] LaMarr Downey. 2024. (May 2024).

[4] Przemyslaw Dymarski (Ed.). 2011. *Hidden Markov Models, Theory and Applications*. InTech, Rijeka, Croatia. <http://www.intechopen.com>

[5] A. Gupta and B. Dhingra. 2012. Stock market prediction using Hidden Markov Models. In *2012 Students Conference on Engineering and Systems*. 1–4. <https://doi.org/10.1109/SCES.2012.6199099>

[6] R. S. Mamon and R. J. Elliott (Eds.). 2014. *Hidden Markov Models in Finance: Further Developments and Applications, Volume II* (1 ed.). Vol. II. Springer US. <https://doi.org/10.1007/978-1-4899-7442-6>


[7] Lawrence R. Rabiner. 1989. A tutorial on hidden markov models and selected applications in speech recognition. *Proc. IEEE* 77, 2 (1989), 257–286.

[8] Grand View Research. 2025. High Frequency Trading Market Size | Industry Report, 2030. (2025). <https://www.grandviewresearch.com/industry-analysis/high-frequency-trading-market-report/toc>


[9] John Stachurski and Thomas J. Sargent. 2022. *Economic Networks: Theory and Computation*. (2022). <https://networks.quantecon.org/QuantEcon>.

[10] Gregory Zuckerman. 2019. *The Man Who Solved the Market: How Jim Simons Launched the Quant Revolution*. Portfolio.

dataBOGOTA.csv - Predicciones (Modelo óptimo: 2 estados)



(a) Banco de Bogotá: Predicciones sobre Velas Japonesas



(b) Terpel: Predicciones en serie de tiempo

Figure 3: Visualización de las Predicciones del Modelo HMM (2 Estados). Los puntos sobre las velas indican la señal de trading generada por el modelo (Verde = Acierto, Rojo = Error). Se observa cómo el modelo logra capturar tendencias sostenidas durante periodos de alta volatilidad.